

Clasificación de enfermedades en hojas de té

Azul Rosales | A01706348

Abstract

Este trabajo presenta un enfoque para la clasificación de enfermedades en hojas de té utilizando EfficientNet y técnicas de transfer learning. Dado que las bases de datos de imágenes de enfermedades de plantas suelen ser limitadas, se emplea transfer learning para aprovechar modelos pre entrenados, como EfficientNet, entrenados con grandes conjuntos de datos (como ImageNet). Este enfoque permite obtener buenos resultados incluso con un número reducido de muestras, mejorando la precisión en la identificación de enfermedades específicas en hojas de té.

Introducción

Las hojas de té, uno de los cultivos más valiosos a nivel mundial, son susceptibles a una amplia variedad de enfermedades causadas por patógenos como hongos, bacterias y virus. La detección temprana y precisa de estas enfermedades es crucial para la salud de las plantas, la calidad del producto final y la rentabilidad de las cosechas.



Enfermedades en hojas de té

Tradicionalmente, la identificación de estas enfermedades ha dependido de inspecciones visuales, lo que requiere mucho tiempo y puede no ser lo suficientemente preciso. Además, las condiciones ambientales y las similitudes entre diferentes enfermedades pueden hacer que el diagnóstico sea desafiante incluso para los expertos. [1]


Gracias al aprendizaje automático es posible automatizar el proceso de detección de enfermedades en hojas de té mediante imágenes. El uso de modelos pre entrenados, como EfficientNet, podría permitir a los investigadores y agricultores clasificar y diagnosticar estas enfermedades de manera eficiente, incluso con un número limitado de muestras, lo que representa una ventaja significativa en áreas donde la recopilación de datos es costosa o limitada.

Metodología

I. Dataset

El dataset utilizado está compuesto por imágenes etiquetadas según la enfermedad que presenta. Las clases incluídas son:

- *Healthy*: hojas saludables sin signos visibles de enfermedad.
- *White Spot*: hojas afectadas por manchas blancas características de esta enfermedad.
- *Anthrachnose*: manchas necróticas oscuras causadas por infecciones fúngicas del género *Colletotrichum*.
- *Gray Light*: hojas con manchas grises, posiblemente causadas por infecciones fúngicas o condiciones ambientales adversas.
- *Bird Eye Spot*: manchas circulares, que se asemejan a los ojos de un pájaro, generalmente causadas por infecciones.
- *Algal Leaf*: hojas infectadas por algas, mostrando manchas irregulares de color.
- *Brown Blight*: manchas marrones que afectan la vitalidad de las hojas.
- *Red Leaf Spot*: manchas rojas causadas por infecciones virales o fúngicas.



Distribución de muestras por clase

La distribución de las clases en el dataset muestra cierta variabilidad en la cantidad de imágenes disponibles por clase. Algunas clases, como *White Spot* y *Red Leaf Spot*, tienen una mayor cantidad de imágenes en comparación con otras clases, como *Anthrachnose* o *Gray Light*.

II. Procesamiento de datos

Los datos se separaron en un split de 80/20, donde el 80% de los datos fueron para entrenamiento y el restante 20% fue para validación.

Además, se pre procesaron los datos de la siguiente manera:

- *En entrenamiento:* transformaciones aleatorias (recortes, flips) para aumentar la variabilidad y ayudar al modelo a generalizar mejor.
- *En validación:* transformaciones fijas (redimensionamiento y recorte central).

III. Métricas

Para evaluar y seleccionar el modelo óptimo, se utilizaron tres métricas: precisión, recall, F1 score y matriz de confusión:

- *Recall:* Representa la proporción de verdaderos positivos detectados sobre el total de casos positivos reales. Útil para minimizar los falsos negativos donde es crítico identificar la mayor cantidad de posibles instancias positivas - este es nuestro caso ya que no identificar una planta que esté enferma puede ser muy costoso.

$$\text{Recall} = \frac{tp}{tp + fn}$$

- *F1 Score:* Es la media armónica entre la precisión y el recall, proporcionando una única métrica que balancea ambas. Es especialmente valioso cuando se tienen clases desbalanceadas, ya que toma en cuenta tanto los falsos positivos como los falsos negativos.

$$\text{F1-score} = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

- *Matriz de confusión:* Esta herramienta visualiza el desempeño del modelo al mostrar el número de predicciones correctas e incorrectas para cada clase. La matriz permite identificar fácilmente qué clases son más difíciles de distinguir para el modelo.

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Estas métricas proporcionan una visión integral del desempeño del modelo, permitiendo analizar su capacidad para clasificar correctamente las enfermedades en las hojas.

IV. Experimentación y construcción de modelos

Para abordar el problema, se tomó como base el modelo EfficientNet B0 entrenado previamente en el conjunto de datos ImageNet (un dataset gigante que incluye muchísimas clases del mundo). Este modelo ha demostrado ser altamente eficiente en tareas de clasificación de imágenes debido a su arquitectura optimizada y su capacidad para manejar eficientemente la computación. [2]

a. Pre-training and fine-tuning

Como primer enfoque, se fine-tuneó el modelo EfficientNet B0 entrenado en ImageNet. Para ello, se entrenó toda la red nuevamente con nuestro dataset partiendo de los pesos del modelo pre entrenado. En este paso, se reemplazó la capa final del modelo para ajustarla al número de clases presentes (8 clases). Esto permitió ajustar los parámetros de la red a las características específicas del nuevo conjunto de datos.

Entrenar un modelo para ajustarlo a datos específicos partiendo de los pesos de un modelo pre entrenado en lugar de con pesos random corresponde a un técnica conocida como *pre-training and fine-tuning*. Esto permite que la convergencia se acelere al momento de entrenar el modelo en el dataset específico y puede mejorar la precisión cuando este dataset tiene un número de muestras pequeño [3].


Configuración del entrenamiento:

- Optimizador: Adam
 - Learning rate: $1e-4$
 - Weight decay*: $1e-5$
 - Criterio: cross entropy loss
- Epochs: 30**

**El weight decay fue empleado ya que es una técnica de regularización que ayuda a evitar el sobreajuste del modelo, especialmente cuando se trabaja con un conjunto de datos pequeño.*

***Originalmente se intentó con 10 epochs pero no fueron suficientes para que el modelo aprendiera correctamente, por lo que se intentó con un número mayor de epochs y 30 resultó ser el que dio mejores resultados.*

Resultados:



Matriz de confusión

- Recall: 0.88
- F1 Score: 0.88

Se observa que el modelo tiene una alta precisión en la mayoría de las clases, a excepción de *Anthracnose*, *Gray Light*, y *White Spot*, que sufre de confusiones con otras clases. Por otro lado, el recall de 0.88 indica que el modelo identifica correctamente el 88% de las muestras positivas para cada clase. Esto sugiere que el modelo tiene una buena capacidad para detectar la mayoría de los casos relevantes (como igual se puede ver en la matriz de confusión). Además, el F1 Score de 0.88 muestra que el modelo tiene un rendimiento equilibrado.

b. Transfer Learning

Como segundo enfoque, se empleó el paradigma de *transfer learning*, el cual es útil cuando solo se cuenta con una muestra limitada de datos. En este caso, se usó el modelo pre entrenado como un *feature extractor*: se congelan los pesos del modelo pre entrenado y encima se le agregan nuevas capas que se entrenan con el dataset. La ventaja de esto podría ser que, al mantener congeladas las capas pre-entrenadas, evitas que el modelo modifique drásticamente sus características bien generalizadas. [4]

Capas añadidas para el entrenamiento:


- Una capa densa (Linear).
- Una función de activación ReLU que introduce no linealidad.

- Un Dropout del 30% para evitar sobreajuste.
- Una capa final (Linear) que proyecta a las 8 clases del problema de clasificación.

Configuración del entrenamiento:

- Optimizador: Adam
 - Learning rate: 1e-4
 - Weight decay: 1e-5
 - Criterio: cross entropy loss
- Epochs: 30

Resultados:



Matriz de confusión

- Recall: 0.84
- F1 Score: 0.84

Se puede observar que el modelo tuvo un peor desempeño siguiendo este método. Esto posiblemente sea debido a que el extractor no está especializado en el dominio de las plantas o en las hojas de té más específicamente, ya que este está entrenado con ImageNet (un dataset muy general pero poco específico que parece que no se transfiere muy bien en este caso).

c. Fine-tuning progresivo

En este tercer enfoque, se intenta combinar las dos ventajas potenciales de los enfoques anteriores usando haciendo un híbrido:

1. Empezar congelando el extractor y entrenando la cabeza nueva (por 10 epochs).

Configuración del entrenamiento:

- a. Optimizador: Adam
 - i. Learning rate: 1e-3
 - ii. Criterio: cross entropy loss
 - b. Epochs: 10
- Y se añadieron las mismas capas que anteriormente para el clasificador.


- 2. Descongelar todo el modelo pre entrenado y continuar entrenando pero con learning rate más bajo (por 20 epochs).

Configuración del entrenamiento:

- b. Optimizador: Adam
 - i. Learning rate: 1e-4
 - ii. Weight decay: 1e-5
 - iii. Criterio: cross entropy loss
- b. Epochs: 20

Este método está inspirado en *AutoFreeze* un sistema que utiliza un enfoque adaptativo para elegir qué capas entrenar, mostrando cómo esto puede acelerar el fine-tuning del modelo mientras se preserva la precisión. [5]

Resultados:



Matriz de confusión

- Recall: 0.93
- F1 Score: 0.93

El modelo tuvo un mejor recall y F1 score que los anteriores. En la matriz de confusión se puede observar que la precisión a nivel clase no es tan buena en algunos casos a comparación con el primer modelo generado con *fine-tuning*, pero al menos esta precisión es más uniforme en promedio a través de las clases.

Conclusiones

Este estudio demuestra el potencial del uso de modelos pre entrenados para la clasificación de enfermedades en hojas de té mediante técnicas de transfer learning. Se evaluaron tres enfoques principales: fine-tuning completo, uso del modelo como extractor de características, y un enfoque híbrido con congelamiento inicial seguido de entrenamiento completo (fine-tuning progresivo).

La estrategia de transfer learning con un entrenamiento progresivo resulta ser una alternativa poderosa para resolver tareas de clasificación con datos limitados, permitiendo aprovechar el conocimiento previo de modelos grandes como EfficientNet y adaptarlo eficientemente a nuevos dominios.

Posible mejora:

- Para mejorar la transferencia de conocimiento, se podrían explorar modelos pre entrenados en datasets agrícolas como *PlantVillage*, que contiene imágenes de hojas de cultivos con diferentes enfermedades. [6]

Referencias:

1. Bao, W., Fan, T., Hu, G., Liang, D. & Li, H. Detection and identification of tea leaf diseases based on AX-RetinaNet. Sci. Rep. 12(1), 1–16. <https://doi.org/10.1038/s41598-022-06181-z> (2022).
2. Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. arXiv preprint arXiv:1905.11946.
3. He, K., Girshick, R., & Dollar, P. (2019). Rethinking ImageNet Pre-training. Facebook AI Research (FAIR). <https://arxiv.org/abs/1811.08883>
4. Tan, C., Sun, F., Kong, T., Zhang, W., Yang, C., & Liu, C. (2018). A Survey on Deep Transfer Learning. Proceedings of the International Conference on Artificial

Intelligence and Statistics (AISTATS), 21, 330-339.

<https://arxiv.org/abs/1808.01974>

5. Liu, Y., Agarwal, S., & Venkataraman, S. (2021). AutoFreeze: Automatically freezing model blocks to accelerate fine-tuning. *arXiv*.
<https://doi.org/10.48550/arXiv.2102.01386>
6. P, P. J., & Sethi, A. (2021). Which Backbone to Use: A Resource-efficient Domain Specific Comparison for Computer Vision. In Proceedings of the International Conference on Computer Vision (ICCV), 1-10. <https://arxiv.org/abs/2406.05612>